Baltic Computer Systems
BCS Koolitus

BCS Koolitus

Vali Andmetarkus!

LÕPUTÖÖ

Andmepõhine e-poe ostukäitumise ja kliendibaasi analüüs probleemide ja arenguvõimaluste tuvastamiseks müügi suurendamise eesmärgil

Koostaja: Svetlana Sizmina

Juhendaja: Emilie Abel

Tallinn 2026

1. SISSEJUHATUS JA PROBLEEMI PÜSTITUS

1.1 Eesmärk ja aktuaalsus:

E-pood loodi pandeemia tõttu 2020. aasta lõpus, kuid seni ei ole selle tegevust põhjalikult analüüsitud. E-pood ei ole ettevõtte põhitegevus, vaid täiendav tegevussuund. Kuigi äritarkvara võimaldab jälgida müüki kaubagruppide ja toodete kaupa, on ostjate käitumist ja kliendibaasi struktuuri käsitlevad andmed jäänud analüüsimata. Käesoleva töö eesmärk on uurida poe arengudünaamikat ja peamisi tendentse ning analüüsida kliendibaasi ja klientide käitumist, et tuvastada probleemsed valdkonnad ja kasvuvõimalused müügi suurendamiseks.

1.2 Uurimisküsimused

- Kuidas on e-poe müük aastatel 2020–2026 muutunud ja milline on müügi üldine trend?
- Milline on e-poe klientide ostukäitumine ja ostude korduvus?
- Kui suur osa ostukorvidest jääb lõpetamata ja milline on nende väärtus?
- Milline on e-poe kliendibaas ja kuidas see on aastate jooksul muutunud?
- Millised probleemid ja arenguvõimalused selguvad analüüsi põhjal ning kuidas neid müügi suurendamiseks kasutada?

1.3 Ärimõisted

- Netokäive – täidetud tellimuste koguväärtus valitud perioodil ilma käibemaksuta ja pärast allahindluste mahaarvamist
- Netokäibe kasvumäär – näitab netokäibe muutust võrreldes eelmise perioodiga protsentides
- Keskmine tellimuse väärtus (AOV) – keskmine summa, mille klient ühe täidetud tellimuse kohta kulutab
- Müüdud toodete arv – valitud perioodil täidetud tellimustes müüdud toodete kogus
- Täidetud tellimus – tellimus, mille puhul klient on ostu edukalt lõpetanud
- Tühistatud tellimus – tellimus, mis on enne täitmist tühistatud
- Ostukäitumine – klientide ostude sagedus, korduvus ja ostude väärtus valitud perioodil
- Ostukorv – e-poes loodud ostukorv, mis sisaldab kliendi valitud tooteid ja nende koguseid
- Konverteerutud ostukorv – ostukorv, mille tulemusena tehti tellimus
- Hüljatud ostukorv – ostukorv, mille puhul tellimust ei lõpetatud
- Aktiivne ostukorv – ostukorv, mille puhul ostuprotsess on pooleli
- Kliendibaas – e-poest ostnud klientide kogum, keda on võimalik ostude põhjal identifitseerida ja analüüsida

- Ühekordne klient – klient, kes on analüüsitaval perioodil teinud ühe täidetud ostu
- Ühekordsete klientide osakaal – ühekordsete klientide osakaal kõigist analüüsitava perioodi klientidest
- Korduvostuga klient – klient, kes on analüüsitaval perioodil teinud vähemalt kaks täidetud ostu
- Korduvklientide osakaa**l** – korduvostuga klientide osakaal kõigist analüüsitava perioodi klientidest
- Ostud kontoga – ostud, mis on tehtud kliendikontoga
- Ostud ilma kontota – ostud, mis on tehtud ilma kliendikontota
- Klient kontoga – klient, kes on e-poes registreeritud ja kelle ostud on seotud kliendikontoga.
- Klient ilma kontota – klient, kes ei ole e-poes registreerunud ja kes ostis nagu külaline

2. ANDMEALLIKATE JA ANDMEVOO KIRJELDUS

2.1 Andmeallikad ja andmevoog

Analüüsiks vajalikud andmed saadi ettevõtjalt CSV-failidena. Esmalt kontrolliti ja puhastati andmed ning salvestati puhastatud andmed SQL-andmebaasi. Seejärel loodi SQL-is fakt- ja dimensioonitabelid. Osa analüüsist tehti Pythonis ning tulemused salvestati Exceli failidesse.

Seejärel imporditi fakt- ja dimensioonitabelid ning Pythonis tehtud analüüsi tulemused Power BI-sse. Power BI-s loodi tabelite vahel vajalikud seosed, tehti täiendavad arvutused ning koostati analüütiline aruanne ja visualiseeringud.

Andmevoog: CSV-failid → andmete kontrollimine SQL → andmete puhastamine SQL → fakt- ja dimensioonitabelid SQL → analüüs Pythonis → Excelis → Power BI → analüüs ja visualiseerimine.

2.2 Andmemudel

Figure 1 on esitatud Power BI-s kasutatud andmemudel, mis sisaldab SQL-is loodud fakt- ja dimensioonitabeleid ning Pythonis tehtud analüüsi tulemuste tabeleid. Joonisel on näidatud tabelite vahelised seosed.

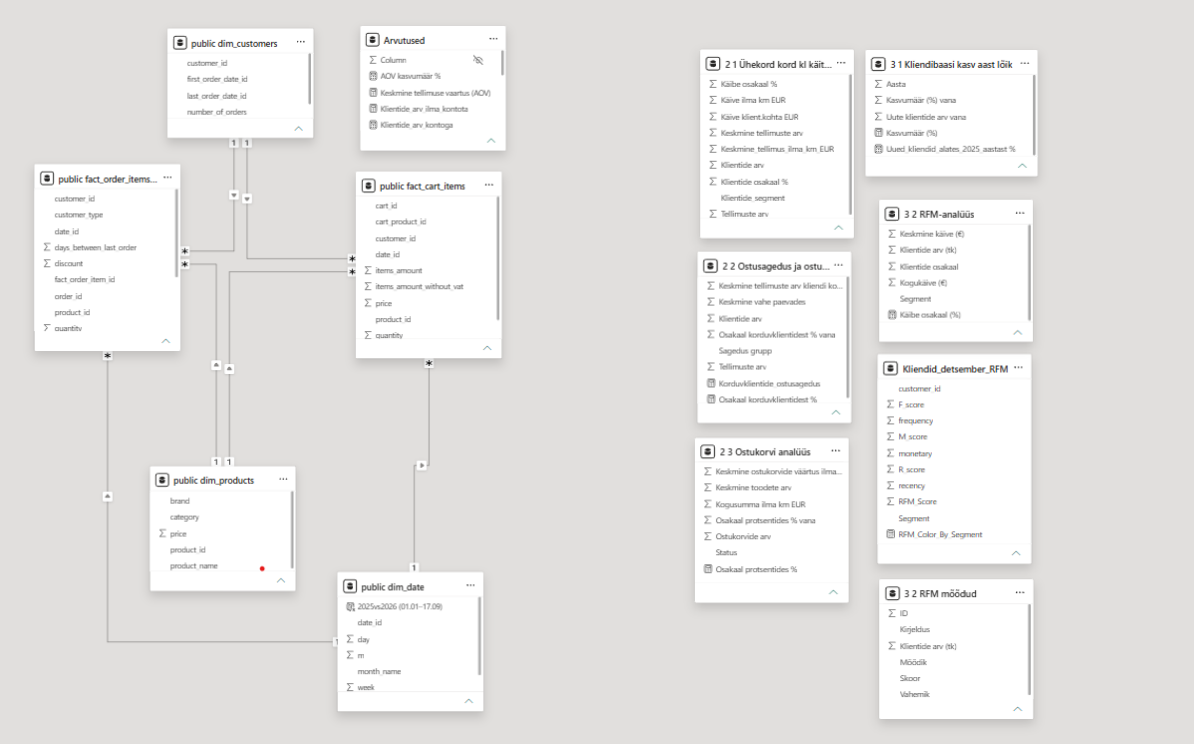


Figure 1 Power BI-s kasutatud andmemudel

2.3 Andmete maht ja profiil

Analüüsi aluseks olevad andmed saadi ettevõtjalt CSV-failidena. Andmed hõlmavad perioodi 2020–2026 ning sisaldavad e-poe tellimuste, klientide, toodete ja ostukorvidega seotud infot. Tabelis X on esitatud analüüsis kasutatud tabelite maht ja andmete ajavahemik.4

1 Analüüsis kasutatud tabelite maht ja andmete periood

Fail	Veergude nimetused	Veergude arv	Ridade arv	Min kuupäev / Max kuupäev
Customers	customer_id, first_order_date	2	3529	
Order_customer_type	order_id, customer_type	2	5167	
Products	product_id, product_name, category, brand, price	5	7408	
Orders	order_id, customer_id, order_date, status, total_amount	5	5167	15.12.2020-17.09.2026
Order_items	order_id, product_id, quantity, unit_price, discount	5	16092	
Carts	cart_id, customer_id, created_at, updated_at, status, total_amount	6	1104	23.07.2026-18.09.2026
Cart_items	cart_id, product_id, quantity, price	4	2830	

3. ANDMETÖÖTLUS

3.1 Andmekaitse

Analüüsiks kasutatud andmed olid eelnevalt anonümiseeritud ning ei sisaldanud klientide otseselt tuvastatavaid isikuandmeid, nagu nimi, e-posti aadress või telefoninumber. Lisaks olid toodete nimetused, kategooriad ja hinnad muudetud, et analüüsis ei kasutataks ettevõtte tegelikke ärilisi andmeid. Andmeid kasutati ainult e-poe müügi, ostukäitumise ja kliendibaasi analüüsimiseks.

3.2 Andmekvaliteet ja andmete puhastamine

Andmete kontrollimise käigus leiti mitmeid puudusi ja erinevusi tabelites. Andmete kvaliteedi parandamiseks kontrolliti puuduvaid väärtusi, tellimuste staatusi, hindasid ning tabelite omavahelist vastavust.

- Tabelis carts esines 904 kirjet, millel puudus customer_id. Need kirjed jäeti andmestikku, kuna tegemist oli lõpetamata ostukorvidega, mille puhul kliendi ID ei olnud loodud.
- Tabelis orders esines erinevaid tellimuste staatusi: 26 puuduva staatusega NULL tellimust, 1 staatuses holded, 602 staatuses pending, 4046 staatuses processing ja 1 staatuses closed. Andmete tähenduse täpsustamiseks pöörduti ettevõtja poole. Ettevõtja selgituse kohaselt käsitleti staatuseid holded, pending ja closed tühistatud tellimustena ning staatust processing täidetud tellimusena. NULL staatusega 26 tellimust käsitleti testtellimustena ja need eemaldati analüüsist.
- **Fact_order_items** tabeli loomisel avastati tellimustes anomaaliaid. days_between_last_order arvutamisel leiti kliente, kellel oli samal kuupäeval mitu sarnast tellimust. Täiendaval kontrollimisel leiti 44 kahtlast tellimust. Näiteks oli üks klient tellinud sama toodet samal päeval kümme korda. Kahtlased tellimused edastati ettevõtjale kontrollimiseks. Ettevõtja selgituse põhjal olid 36 tellimust testtellimused ja need eemaldati. Kaks tellimust ei läbinud makset ning eemaldati samuti. Kuus tellimust olid seotud tegelike ostudega ning need ühendati üheks tellimuseks. Loodi uus tabel **Fact_order_items_clean**.
- Kontrollimisel leiti kaks tellimust, 118125 ja 118204, milles esines toode P007290 hinnaga 0. Tellimus 118204 sisaldas ainult ühte nullhinnaga toodet ning ettevõtja loal eemaldati see analüüsist. Tellimus 118125 jäeti alles, kuna selles sisaldus lisaks nullhinnaga tootele ka teisi tooteid.
- Ostukorvide puhul ei langenud tabelite carts ja cart_items andmed alati kokku. Tabeli carts väli total_amount sisaldas lisaks toodete väärtusele kasutatud sooduskuponge ja kohaletoimetamise tasu. Seetõttu arvutati ostukorvi toodete väärtus analüüsis valemiga quantity × price – käibemaks
- Sarnane erinevus esines tabelites order_items ja orders. Väljade quantity, unit_price ja discount põhjal arvutatud summa ei langenud kokku tabeli orders väljaga total_amount, kuna viimases sisaldus ka kohaletoimetamise tasu. Analüüsis kasutati seetõttu tellimuse toodete väärtuse arvutamiseks valemit (quantity × unit_price – discount)-käibemaks
- Tabelis order_items leiti üheksa toodet: PX000001, PX000002, PX000003, PX000004, PX000005, PX000006, PX000007, PX000008 ja PX000009, mida ei olnud tootekataloogis. Ettevõtja selgituse kohaselt olid tegemist tootevalikust eemaldatud toodetega. Need tooted analüüsis ei kasutatud.

- Tootekataloogis leiti ka toode P002608, mille hind oli 0,01 eurot. Tegemist võis olla andmekaitsega ettevõtjapoolt ning seda väärtust tuleb analüüsi tulemuste tõlgendamisel arvesse võtta.
- Lisaks leiti 2232 tootekirjet, mille ühel väljal oli mitu kaubamärki kokku pandud ühele reale. Kuna käesolevas töös kaubamärkide ja kategooriate põhist analüüsi ei tehta, jäeti need väärtused muutmata.

3.3 Andmete transformeerimine ja rikastamine

Pärast andmete puhastamist valmistati andmed ette edasiseks analüüsiks. SQL-is loodi puhastatud andmete põhjal fakt- ja dimensioonitabelid ning ühendati analüüsiks vajalikud andmed. Samuti loodi uusi tunnuseid ja arvutatud väärtusi, mida kasutati klientide, tellimuste ja ostukäitumise analüüsimiseks.

Analüüsi käigus tehti mitmesuguseid arvutusi, sealhulgas tellimuste, klientide, ostukorvide ja müügituluga seotud näitajate arvutusi. Arvutused tehti vastavalt analüüsi eesmärkidele ning kasutati hiljem analüüsis ja visualiseerimisel.

Osa analüüsiarvutustest tehti Pythonis ning tulemused salvestati Exceli failidesse. Seejärel imporditi vajalikud tabelid ja arvutuste tulemused Power BI-sse, kus loodi tabelite vahelised seosed ning tehti täiendavad arvutused.

4. ANALÜÜS JA VISUALISEERIMINE

4.1 Analüüsi metoodika

Analüüsi eesmärk oli hinnata e-poe müügi arengut, klientide ostukäitumist, ostukorve ja kliendibaasi perioodil 2020–2026. Analüüsi tegemisel kasutati SQL-i, Pythonit ja Power BI-d.

SQL-is valmistati andmed ette edasiseks analüüsiks ning loodi fakt- ja dimensioonitabelid. Samuti arvutati analüüsiks vajalikud tunnused, näiteks tellimuste arv ning käive koos ja ilma käibemaksuta.

Pythonis viidi läbi põhjalikum analüüs, mis hõlmas ühekordse ja korduvostuga klientide ostukäitumist, ostusagedust ja ostude korduvust, ostukorvide analüüsi ning kliendibaasi kasvu aastate lõikes. Lisaks tehti Pythonis RFM-analüüs klientide aktiivsuse ja väärtuse hindamiseks.

Ühekordse ja korduvostuga klientide analüüsimisel võrreldi klientide ostude arvu ja nende panust müüki. Ostusageduse analüüsimisel vaadeldi, kui sageli kliendid e-poest ostsid ja kui suur oli korduvostude osakaal.

Ostukorvi analüüsis võrreldi konverteerunud ja hüljatud ostukorve ning hinnati hüljatud ostukorvide võimalikku müügitulu. Kliendibaasi analüüsis vaadeldi klientide arvu ja selle muutust aastate lõikes.

RFM-analüüsis hinnati kolme näitajat: **Recency** ehk viimase ostu värskus, **Frequency** ehk ostude sagedus ja **Monetary** ehk kliendi ostude rahaline väärtus. Nende näitajate põhjal hinnati klientide aktiivsust ja väärtust e-poele.

Frequency näitaja jaotamisel ei kasutatud klientide tavapärast jagamist võrdsetesse rühmadesse, kuna ligikaudu 85% klientidest olid teinud ainult ühe ostu. Seetõttu kasutati ostude arvul põhinevat jaotust: **1 ost = 1, 2 ostu = 2, 3 ostu = 3, 4–5 ostu = 4 ning 6 ja rohkem ostu = 5**.

Power BI-s arvutati aruande peamised mõõdikud, sealhulgas netokäive, keskmine tellimuse väärtus (AOV), täidetud ja tühistatud tellimuste arv, müüdud toodete arv ning nende kasvumäärad. Lisaks arvutati klientide ja ostude jaotus kliendikonto olemasolu järgi ning vastavad osakaalud.

4.2 Analüüsi tulemused ja visualiseerimine

Analüüsi tulemused esitati tabelite ja visualiseeringutena. Analüüs keskendus e-poe müügi arengule, klientide ostukäitumisele, ostukorvidele ja kliendibaasile.

Müügi analüüsis vaadeldi netokäivet, keskmist tellimuse väärtust, täidetud ja tühistatud tellimusi ning müüdud toodete arvu. Näitajaid võrreldi aastate lõikes, et tuvastada olulisemad muutused ja trendid.

Klientide analüüsis vaadeldi ühekordsete ja korduvostuga klientide osakaalu, ostusagedust ning kliendibaasi muutust aastate lõikes. Ostukorvide analüüs võimaldas hinnata hüljatud ostukorvide osakaalu ja nende võimalikku müügitulu.

RFM-analüüsi abil hinnati klientide aktiivsust ja väärtust ning eristati erineva ostukäitumisega kliendirühmi.

Analüüsi tulemused visualiseeriti Power BI-s. Aruandes kasutati filtreid ja visualiseeringute vahelisi seoseid, et võimaldada andmeid vaadelda erinevate perioodide ja näitajate lõikes.

4.3 Kasutajajuhend

Aruandes saab valida soovitud perioodi ja kasutada filtreid andmete täpsemaks vaatlemiseks. Visualiseeringu elemendile vajutamisel saab vaadata vastava näitaja kohta täpsemat infot.

Aruande vaated on jaotatud analüüsi teemade järgi, et kasutajal oleks lihtne liikuda müügi, klientide, ostukorvide ja RFM-analüüsi vahel.

5. ANDMEKORRALDUS

Selles peatükis kirjeldatakse analüüsis kasutatud mõistete, mõõdikute ja arvutusreeglite dokumenteerimist ning andmete ja aruande haldamise põhimõtteid.

5.1 Mõõdikute ja mõistete dokumenteerimine

Analüüsis kasutatud peamised mõisted on kirjeldatud töö esimeses peatükis. Peamiste mõõdikute arvutamisel kasutati ühtseid arvutusreegleid, et tagada tulemuste võrreldavus kogu analüüsitava perioodi jooksul.

Mõõdikute jaotamisel arvestati kasutatud andmete tähendust ning ettevõtjalt saadud täpsustusi. Näiteks käsitleti processing staatusega tellimusi täidetud tellimustena ning holded, pending ja closed staatusega tellimusi tühistatud tellimustena.

5.2 Andmete ja aruande haldamine

Puhastatud andmed ja SQL-is loodud tabelid on aluseks edasisele analüüsile. Pythonis tehtud analüüsi tulemused salvestati Exceli failidesse ning neid kasutati Power BI aruande koostamisel.

Uute andmete lisamisel tuleb andmed esmalt kontrollida ja vajadusel puhastada vastavalt käesolevas töös kirjeldatud põhimõtetele. Seejärel saab uuendada analüüsi ja Power BI aruannet.

6. KOKKUVÕTE JA ARUTELU

6.1 Tulemused ja uurimisküsimustele vastamine

Analüüsi tulemused näitasid, et e-poe müük on alates 2025. aastast kasvanud ning 2026. aastal oli kasv eriti tugev. Seega on e-poe müügil positiivne arengusuund.

Klientide ostukäitumise analüüs näitas, et ligikaudu 85% klientidest on ühekordsed kliendid ja ainult 15% on teinud rohkem kui ühe ostu. See näitab, et e-poel on suur potentsiaal korduvostude ja klientide lojaalsuse suurendamiseks.

Ostukorvide analüüs näitas, et kahe kuu jooksul lõpetati ostuga 16% ostukorvidest, samas kui 74% ostukorvidest jäid lõpetamata. See näitab, et ostukorvide konversiooni parandamine on üks olulisi arenguvõimalusi.

Aastatel 2025–2026 kasvas klientide arv 92% ning viimase kaheksa kuu jooksul lisandus 1078 uut klienti. Seetõttu on oluline lisaks uute klientide hankimisele pöörata tähelepanu ka nende hoidmisele.

RFM-analüüs võimaldas hinnata klientide aktiivsust, ostusagedust ja rahalist väärtust ning eristada erineva ostukäitumisega kliendirühmi.

6.2 Soovitused

Analüüsi põhjal on peamised arengusuunad klientide hoidmine, korduvostude suurendamine ja ostukorvide konversiooni parandamine.

Korduvostude suurendamiseks võiks kasutada kliendisegmentidele suunatud personaalseid e-kirju. Näiteks võiks parimatele klientidele pakkuda lojaalsusprogramme ja personaalseid pakkumisi, uutele klientidele soodustust või boonust järgmiseks ostuks ning potentsiaalsetele püsiklientidele korduvostu soodustavaid pakkumisi. Ohustatud ning uinunud või kaotatud klientidele võiks saata tagasivõitmise kampaaniaid.

Hüljatud ostukorvide vähendamiseks võiks kasutada automaatseid meeldetuletusi ning testida erinevaid ostu lõpetamist motiveerivaid lahendusi, näiteks tasuta kohaletoimetamist, boonuseid või väikeseid soodustusi. Samuti võiks analüüsida ostuprotsessi, et leida võimalikud takistused tellimuse lõpetamisel.

Tellimuste andmete parandamiseks võiks lisada tühistatud tellimustele tühistamise põhjuse. See võimaldaks tulevikus täpsemalt hinnata tühistamiste põhjuseid ja leida võimalusi nende vähendamiseks.

Võimaliku arengusuunana võiks kaaluda ka tellimuse kättesaamist ettevõtte füüsilistest kauplustest, kuna kauplused asuvad erinevates Eesti piirkondades. Selle võimaluse mõju klientide ostukäitumisele tuleks enne laiemat rakendamist eraldi hinnata.

6.3 Piirangud ja edasiarendused

Analüüsi üheks piiranguks oli olemasolevate andmete struktuur ja mõningate andmete puudumine, näiteks tühistatud tellimuste põhjuste puudumine. Samuti ei olnud võimalik analüüsida kõiki kliendikäitumist mõjutavaid tegureid.

Edaspidi võiks analüüsi täiendada tühistamise põhjuste, turunduskampaaniate tulemuste ja kliendisegmentide käitumise jälgimisega. Samuti võiks hinnata erinevate kliendilojaalsuse ja ostukorvi konversiooni parandamise meetmete mõju müügile.

7. GRUPI TÖÖJAOTUS JA ENESEREFLEKSIOON

Käesoleva analüüsi tegin iseseisvalt. Töö tegemisel kasutasin AI-d abivahendina. AI aitas kirjutada ja parandada SQL-i ja Pythoni koodi, koostada ning täiendada töö teksti, lahendada tehnilisi probleeme ja selgitada programmide kasutamist. Samuti aitas AI leida lahendusi olukordades, kus tekkisid vead või probleemid andmetöötluses. Kõik AI abil saadud lahendused ja tulemused kontrollisin ise üle ning kohandasin vastavalt projekti vajadustele.